

2023

Datathon de Criptomoedas

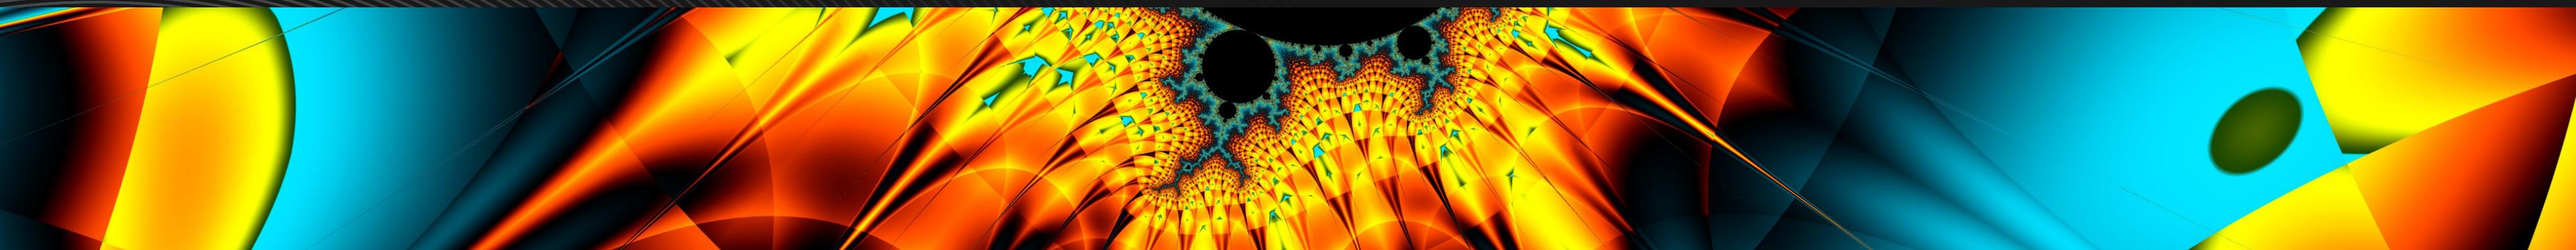
Equipe Cryptal

University Blockchain Research Initiative - UBRI

Faculdade de Economia e Administração - FEAUSP

Heitor Teixeira Couto Campos
Eduardo Amorim Vilela de Salis
Lukas Gherman da Silva
Thais Cordeiro Teixeira
Vinícius Roberto Simões Nazato

Eng. Mecânica EESCUSP
Administração FEAUSP
Administração FEAUSP
Ciências Econômicas FEAUSP
Administração FEAUSP

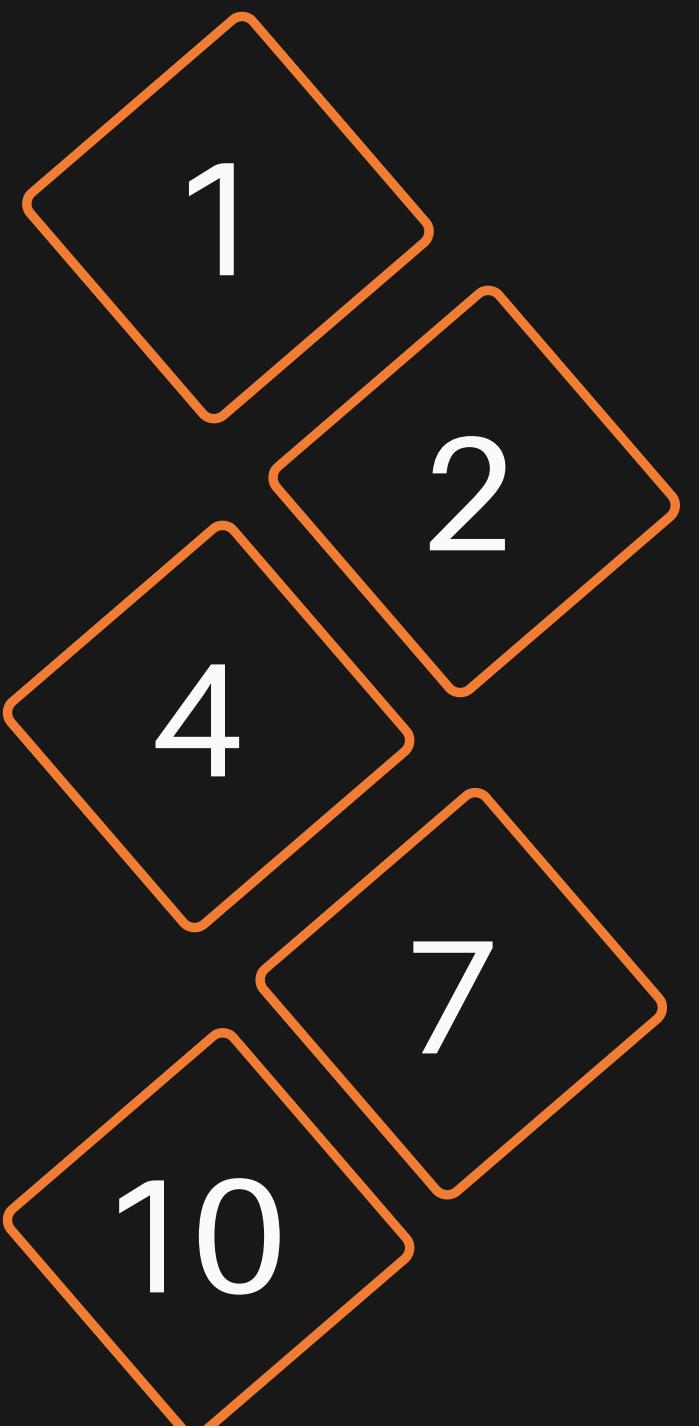


Agenda

Overview

Metodologia

Conclusões



Fundamentação
Teórica

Resultados



Overview

OBJETIVO

- ◆ Propor uma estratégia de investimento baseada em Mercados Fractais para criptomoedas

QUESTÕES DE PESQUISA

- ◆ Os Mercados de Criptomoedas apresentam estruturas multifractais ?
- ◆ Carteiras compostas de moedas mais eficientes promovem uma relação Risco x Retorno melhor?
- ◆ E Carteiras compostas de moedas menos eficientes?
- ◆ Será que uma estratégia de investimento baseada em fractais desempenhará melhores resultados (Fractal Based Portfolio Allocation)?

METODOLOGIA

- ◆ MFDFA - Cálculo de Fractalidade das Moedas (proxy para eficiência)
- ◆ Formação de Carteiras de Markowitz agrupando por moedas mais e menos eficientes.
- ◆ Comparação das Carteiras formadas com benchmarks de Gestão de Carteiras.

INOVAÇÃO

- ◆ Utilização de Medidas de Multifractalidade para composição e otimização de Carteiras de Markowitz



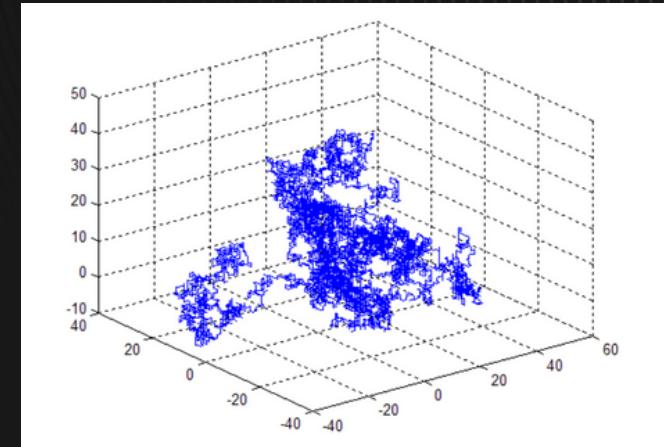
FUNDAMENTAÇÃO TEÓRICA

Hipótese de Eficiência de Mercado

A hipótese do mercado eficiente (HME), definido por Eugene F. Fama (1970), afirma que o preço dos ativos no mercado incorpora todas as informações disponíveis. Neste contexto, podemos especialmente citar a forma fraca da HME, que afirma que as mudanças de preços seguem uma **dinâmica de passeio aleatório**, indicando a impossibilidade de prever o retorno futuro, baseando-se em dados de retornos históricos.

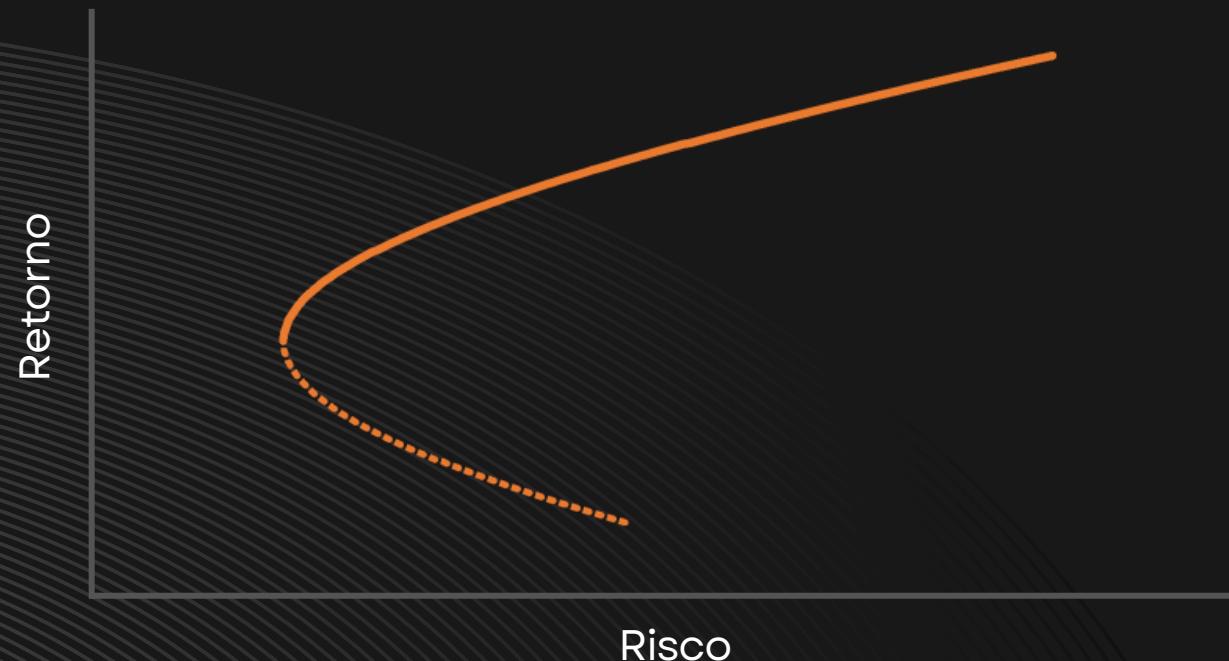
$$P_t = P_{t-1} + E_t$$

Exemplo de um passeio aleatório bidimensional



Exemplo de um passeio aleatório tridimensional

Fronteira Eficiente de Markowitz



Teoria Moderna do Portfólio

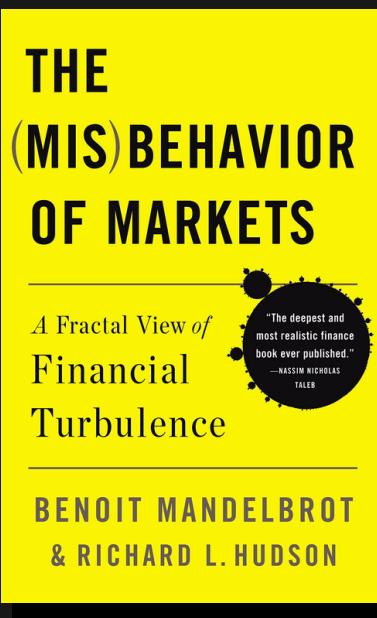
A Teoria Moderna do Portfólio (Markowitz, 1952), ou análise de média-variância, é um modelo de cálculo de risco para criação de um portfólio de ativos de modo que o **retorno esperado seja maximizado dado um determinado nível de risco**. A ideia é que possuir diferentes tipos de ativos financeiros (**carteiras diversificadas**) gera uma carteira com menor risco, do que comparado a carteiras com apenas um tipo. Desta forma, o risco e o retorno de um ativo não devem ser avaliados por si só, mas pela forma como eles contribuem para o risco e o retorno conjunto de um portfólio.

FUNDAMENTAÇÃO TEÓRICA

Hipótese do Mercado Fractal e o MF-DFA

A Hipótese do Mercado Fractal (HMF), afirma que as séries temporais financeiras exibem estruturas auto-afins estocásticas. Isso significa que uma série temporal financeira parece a mesma em diferentes escalas de tempo, pelo menos no sentido estatístico, ou seja, a distribuição dos valores de retornos ao longo de um dia, por exemplo, é semelhante à distribuição de um mês, que é semelhante à distribuição de um ano e assim por diante. Antes restrita apenas ao mercado de ativos convencionais, a literatura atual já trata da HMF dentro do mercado de criptomoedas (Cheng, 2019).

O expoente de Hurst, também conhecido como “índice de dependência/dependência de longo alcance”, é um mecanismo para indicar a memória de longo prazo de uma série temporal. Ele é comumente estudado em geometria fractal, indicando autocorrelações de séries temporais e a taxa em que estas diminuem à medida que a defasagem entre pares de valores aumenta (Hurst, 1951).



Se o expoente de Hurst for $h(q) = 0,5$, a série temporal caracteriza-se como passeio aleatório. Nesse caso, o processo estocástico é aderente à forma fraca de HEM. Quando $0 < h(q) < 0,5$ ($0,5 < h(q) < 1$) a correlação da série temporal é anti-persistente (persistente), indicando a rejeição de uma dinâmica de passeio aleatório.

Neste contexto, o MF-DFA, proposto por Kantelhardt et al. (2002), fornece uma abordagem flexível e eficiente para classificar as séries de acordo com seus níveis de multifractalidade. Um nível de (in)eficiência de mercado é medido por uma medida de deficiência de mercado (MDM), calculada da seguinte maneira (Tiwari, Aye e Gupta, 2019):

$$MDM = \frac{1}{2} (|h(q_{min}) - 0.5| + |h(q_{max}) - 0.5|)$$

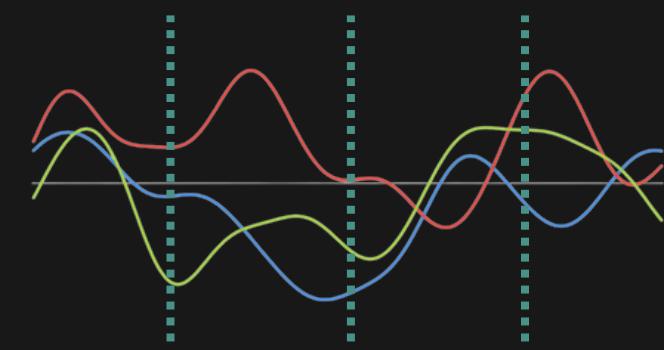
Onde $q(\min)$ e $q(\max)$ são, respectivamente, as ordens mínima e máxima da função de flutuação. Assim, um valor de MDM próximo de zero indica um Mercado Eficiente e quanto maior seu valor, mais ineficiente é o mercado (comportamento de multifractalidade é maior).

METODOLOGIA | PASSO A PASSO



CoinGecko

Extração, das cotações das séries históricas via a API da Coingecko.



Através de um pacote do R que aplica a Hipótese de Mercado Fractal, são calculadas as fractalidades e, subsequente, selecionadas as quatro criptomoedas mais eficientes e as quatro menos eficientes para dois períodos amostrais.



Após a classificação dos ativos segundo seus graus de eficiência, para os respectivos períodos amostrais P1 e P2, são construídas 20 carteiras no total, com seus pesos ponderados para os períodos amostrais P1 e P2 também. Suas respectivas performances são avaliadas para os períodos P1 teste e P2 teste.



Para cada período de testes, são analisadas duas composições de carteiras: as eficientes e as ineficientes, como explicado acima.

Para cada composição, cinco estratégias são utilizadas no cálculo dos pesos dos ativos e quatro métricas na performance das carteiras para os dois períodos de testes.

Maximização Sharpe | Ratio
Variância Mínima
Minimização Condicional Value at Risk
Maximização Retorno
Inverse Inefficiency

Cálculo dos Pesos

Sharpe

Retorno anualizado

Desvio Padrão anualizado

Máximo drawdown

Métricas de resultados

METODOLOGIA | FRACTAIS E SELEÇÃO DE CARTEIRAS

A Hipótese de Mercado Fractal é aplicada nas séries coletadas através do Multifractal Detrended Fluctuation Analysis, pacote do R que permite decompor cada série em N partes*. Ao quebrar-se a série, mapeia-se a ocorrências de padrões entre as partes:

Menor nº de padrões - série tende a ser um Passeio Aleatório - mais eficiente e menor o valor do MDM

| Criptoativos Analisados 2019 - 2022 Setembro | | Eficiência via Fractalidade | Formação de Carteiras | Inverse Inefficiency (Alocação dos criptoativos em função da sua eficiência relativa dentro da carteira. Quanto mais eficiente, maior o peso na carteira, vide próximo slide) | <ul style="list-style-type: none"> • Sharpe • Retorno Anualizado • Desvio Padrão Anualizado • Máximo drawdown |
|---|---------------------------------------|-----------------------------|-----------------------|---|---|
| BNB | Maximização Sharpe Ratio | | | | |
| TRON | Variância Mínima | | | | |
| Ethereum | Minimização Condicional Value at Risk | | | | |
| Bitcoin | Maximização Retorno | | | | |
| Litecoin | | | | | |
| Cardano | | | | | |
| XRP | | | | | |
| Dogecoin | | | | | |
| Ranking dos criptoativos em função da eficiência | | seleção | | Carteira A: quatro + eficientes Carteira B: quatro - eficientes | |
| Apura-se o Risco e o Retorno das estratégias. De forma mais ampla, a rentabilidade em relação ao risco, o retorno acumulado no tempo, o risco histórico e os impactos das quedas, em tempo e magnitude. | | | | | |

- Uma melhor descrição do passo a passo pode ser encontrada na parte de Material Suplementar, no slide Metodologia Fractal Decomposta

RESULTADOS | INVERSE INEFFICIENCY

Modelo de Alocação Heurística: modelos não baseados em teorias ou técnicas matematicamente sofisticadas. Exemplos: "60/40 split", "Risk parity", "1/N" , "Inverse Volatility".

Usando como inspiração o Inverse Volatility, criamos "Inverse Inefficiency" o nosso método de alocação baseado em fractais (fractal based allocation), cujo princípio é alocar uma maior porção do portfólio nos ativos que apresentem menor MDM (i.e mais eficientes). O peso de cada ativo "i" seria calculado por:

$$W_i = \frac{\frac{1}{MDM_i}}{\sum_{j=i}^n \frac{1}{MDM_j}}$$

Para cada período de teste, utilizamos o calculo do MDM obtido no período de treinamento criando a carteira de Inverse Inefficiency.

Distribuição do portfólio

| Tickers | 2021 | 2022 |
|---------|------|------|
| BNB | 15% | 22% |
| TRX | 12% | 15% |
| ETH | 15% | 14% |
| BTC | 10% | 13% |
| LTC | 12% | 11% |
| ADA | 23% | 10% |
| XRP | 7% | 8% |
| DOGE | 6% | 7% |

RESULTADOS | MULTIFRACTALIDADE

| Período 1 - Jan/2019 a Dez/2020 | | Período 2 - Jan/2020 a Dez/2021 | |
|---------------------------------|----------------------|---------------------------------|----------------------|
| Mais eficientes | Menos eficientes | Mais eficientes | Menos eficientes |
| Cardano (0.0778) | TRON (0.1560) | BNB (0.0883) | Litecoin (0.1786) |
| Ethereum (0.1230) | Bitcoin (0.1893) | TRON (0.1311) | Cardano (0.1857) |
| BNB (0.1239) | XRP (0.2530) | Ethereum (0.1423) | XRP (0.2488) |
| Litecoin (0.1485) | Dogecoin (0.2669) | Bitcoin (0.1535) | Dogecoin (0.2601) |

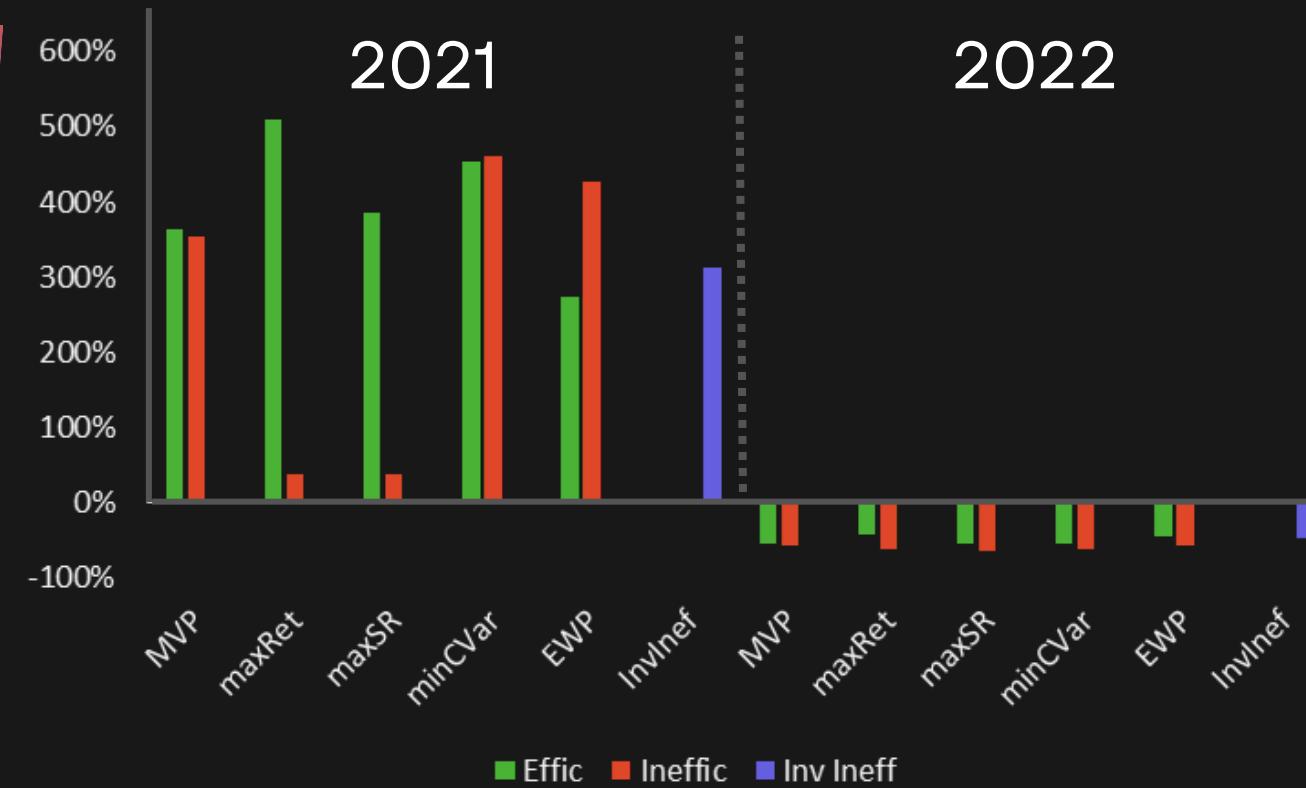
MF - DFA

Baseados nos valores de MDM* - Medida de Deficiência de Mercado, quanto maior a fractalidade da moeda, menos eficiente ela é - classificamos os 4 criptoativos mais e menos eficientes dentro dos dois períodos selecionados, obtendo assim 4 carteiras distintas, as quais serão usadas de insumo para realização da otimização.

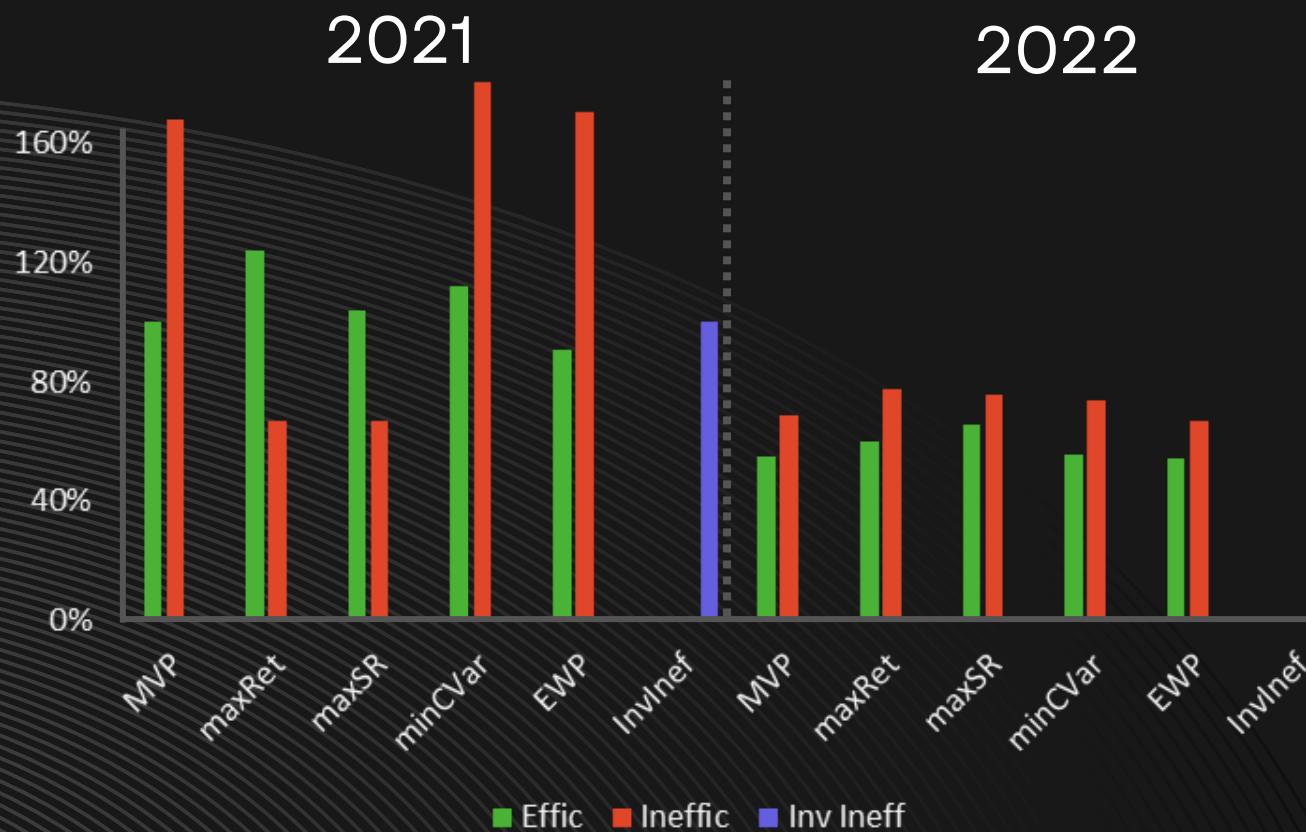


RESULTADOS | OTIMIZAÇÃO DE CARTEIRA

Annualized Return



Annualized Std Dev



Retornos Anualizados

Em 2021, todas as estratégias contendo criptos “eficientes”, com exceção da EWP e da minCVaR, tiveram melhor Retorno do que suas contrapartes “ineficientes”. Destaca-se:

- Estratégias baseadas em maximizar o Retorno: **carteiras eficientes retornam 13x mais quando comparadas às ineficientes** (509% x 38%)
- Estratégias baseadas em maximizar o Sharpe Ratio: **as eficientes retornam 10x mais quando comparadas às ineficientes** (386% x 0.38%)
- Nota-se que para as criptos eficientes, a estratégia ingênua (pesos iguais) obteve um desempenho inferior quando comparada as demais estratégias. Resultado que se inverte para as carteiras ineficientes, nas quais a EWP é a segunda colocada quanto ao sharpe

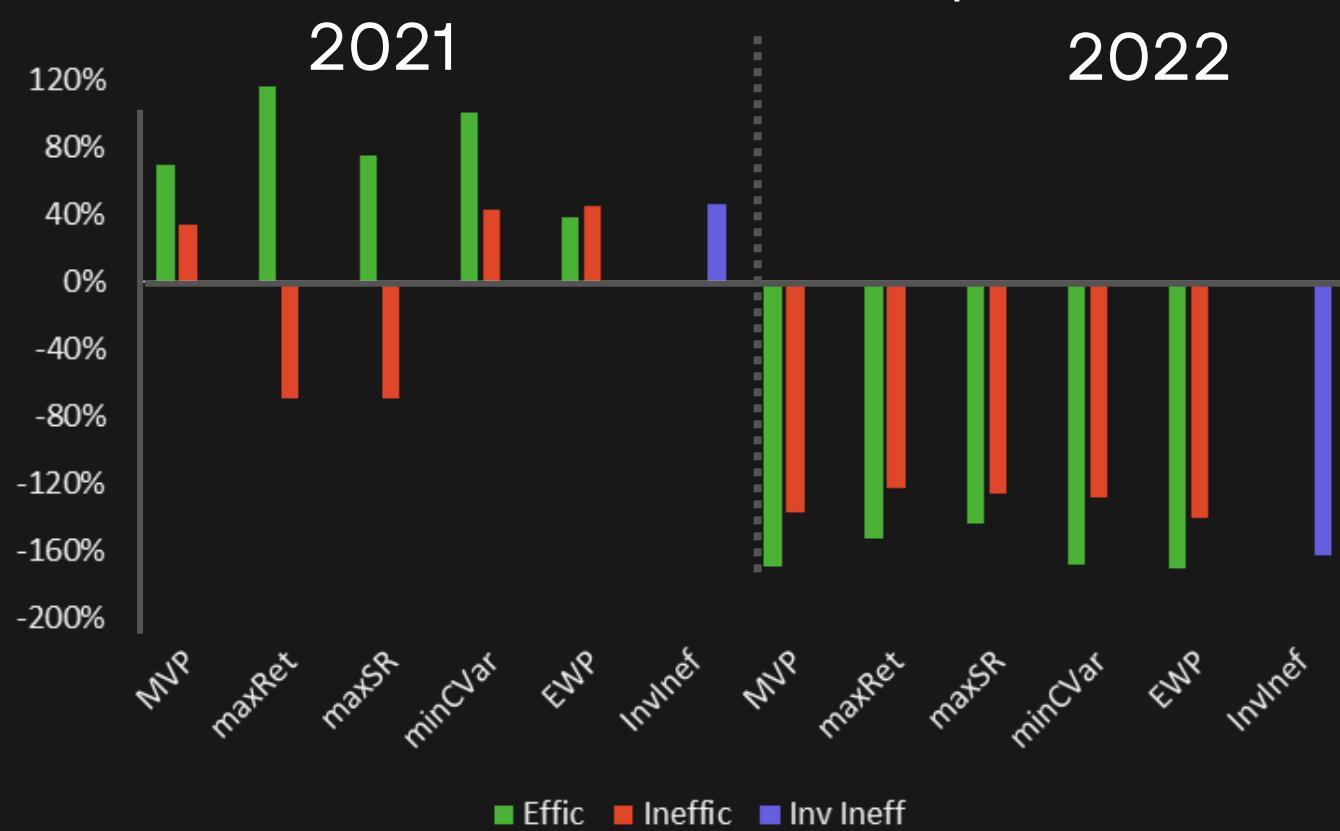
Em 2022, por conta da desvalorização em massa das criptomoedas, não foi observada uma diferença relevante entre as carteiras

Volatilidade Anualizada

Em ambos os anos de análise, com exceção da maxRet e da maxSR, todas as estratégias tiveram menor Vol (desvio padrão anualizado) quando aplicadas para as carteiras contendo “criptos” eficientes

RESULTADOS | OTIMIZAÇÃO DE CARTEIRA

Annualized Sharpe



Sharpe Anualizado

Em 2021, todas as estratégias contendo criptos “eficientes”, com exceção da minCVar, tiveram melhor Sharpe do que suas contrapartes “ineficientes”.

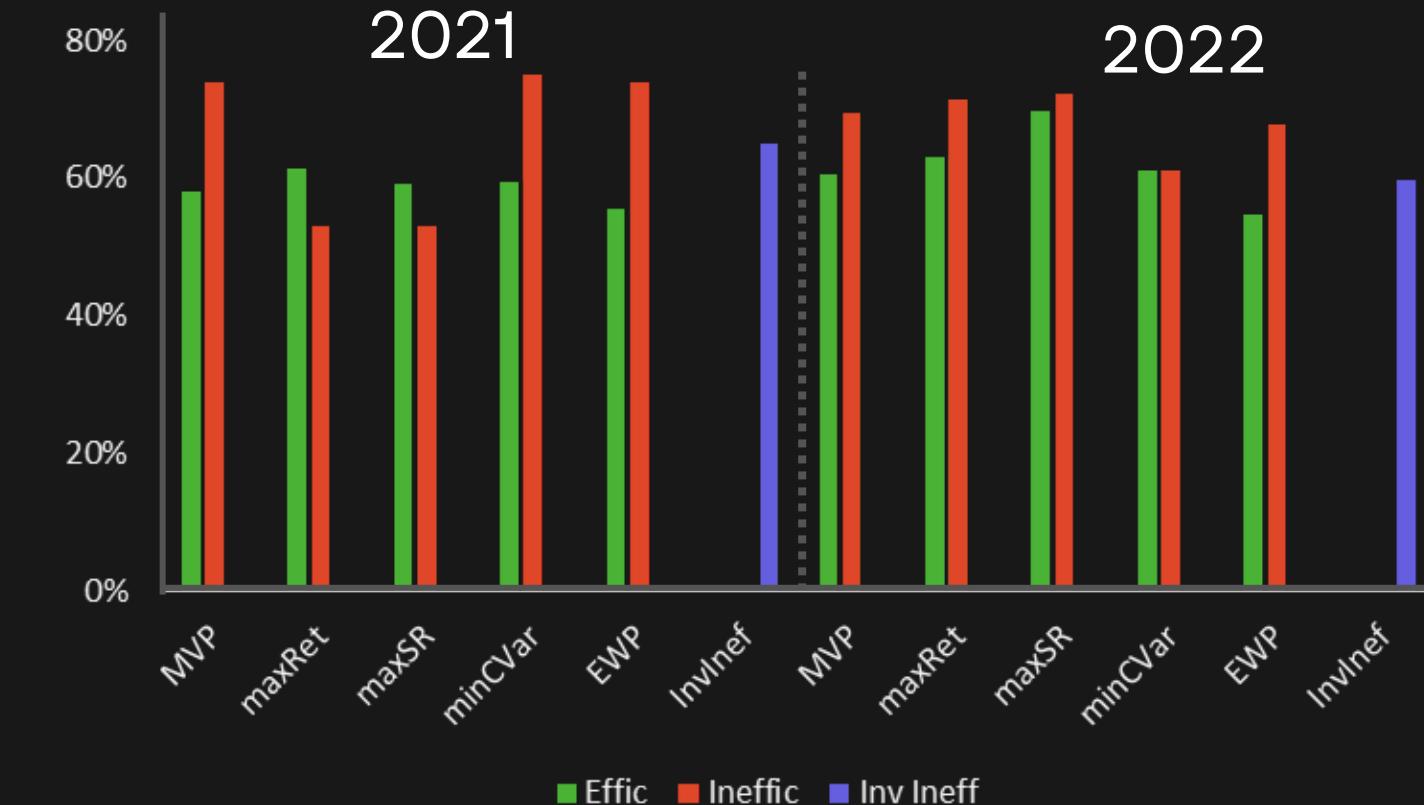
Em 2022, devido à desvalorização das criptomoedas, todas as estratégias apresentaram Sharpe Anualizado negativo. Sendo que as carteiras eficientes consistentemente apresentaram Sharpe relativamente menor (mais negativo) que seus pares ineficientes.

Drawdown Máximo (MDD)

Todas as estratégias e carteiras apresentam MDD acima de 45%, mas cabe destacar que:

- Em 2021, para as estratégias MVP, minCVar e EWP, a carteira ineficiente apresenta MDD superior às contrapartes eficientes. Comportamento que se inverte quando se observa as estratégias de maxRet e maxSR
- Em 2022, todas as estratégias compostas por carteiras ineficientes apresentam MDD mais elevado que seus análogos eficientes
- Em ambos os anos, a alocação Inverse Inefficiency encontra-se em um nível intermediário de MDD

Maximum Drawdown



Considerações Finais

Conclusão

Nesta pesquisa foram avaliadas como carteiras de criptoativos selecionados com base na eficiência dos ativos desempenham perante diferentes estratégias de alocação.

Neste estudo, o rankeamento por eficiência (MDM) foi capaz de selecionar a maioria dos ativos com melhores desempenhos nos períodos fora da amostra. Portanto, abre-se espaço para analisarmos a eficiência como um fator que explique o retorno dos ativos.

Quanto às estratégias de portfólios, percebe-se que os modelos teóricos tiveram (em sua maioria) melhores relações de risco-retorno quando construídas com base nas criptomoedas consideradas eficientes. Em 2021, tais carteiras estiveram entre as que melhor performaram. Já em relação a 2022, ano no qual as criptos sofreram "bear-market", as carteiras "eficientes" obtiveram menores quedas.

Melhorias e análises futuras

Apesar dos resultados positivos encontrados, pontua-se as seguintes melhorias e campos a serem explorados:

- Expandir o universo de criptoativos selecionados
- Analisar como ocorre a distribuição entre ativos do grupo dos eficientes e dos ineficientes dentro das mesmas otimizações
- Acrescentar restrições (limite de posição) e objetivos (meta de diversificação) na construção de políticas de alocação
- Avaliar custos de transação
- Utilizar rebalanceamento do portfólio (reclassificando a eficiência dos ativos)
- Adotar técnicas robustas de estimar risco e retorno
- Adicionar outras KPI's
- Realizar testes estatísticos para avaliar significância das diferenças entre carteiras

Bibliografia

- BLACKLEDGE, J. LAMPHIERE, M. A Review of the Fractal Market Hypothesis for Trading and Market Price Prediction. *Mathematics* 2022, 10, 117
- BreakingFinance.com: <https://breakingdownfinance.com/finance-topics/modern-portfolio-theory/heuristic-asset-allocation-approaches/>
- CHENG, Qing, Xinyuan Liu, and Xiaowu Zhu. 2019. “Cryptocurrency Momentum Effect: DFA and MF-DFA Analysis.” *Physica A: Statistical Mechanics and Its Applications* 526 (July): 120847. <https://doi.org/10.1016/j.physa.2019.04.083>
- FAMA, E. F., Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, v. 25, n. 2, p. 383–417, 1970
- HURST, H. E. Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116(1), 770-799. 1951
- KANTELHARDT, J.W. Zschiegner, S.A. Koscielny-Bunde, E. Havlin, S. Bunde, A.; Stanley, H.E. Multifractal detrended fluctuation analysis of nonstationary time series, *Physica A: Statistical Mechanics and its Applications*, V. 316, n.1-4, p.87-114, 200
- MANDELBROT, B. Hudson, R. Grunwald, E. The (Mis)Behavior of Markets. *Mathematical Intelligencer - MATH INTELL.* 2005
- MARKOWITZ, H. Portfolio selection. *The Journal of Finance*, v. 7, n. 1, p. 77-91, 1952
- TIWARI, A. K., AYE, G. C., GUPTA, R. Stock market efficiency analysis using long spans of data: A multifractal detrendend fluctuation approach. *Finance Research Letters*, 28, 398-411. 2019
- R
 - R Core Team (2022). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. URL <https://www.R-project.org/>.
 - Peterson BG, Carl P (2020). *_PerformanceAnalytics: Econometric Tools for Performance and Risk Analysis_*. R package version 2.0.4, <<https://CRAN.R-project.org/package=PerformanceAnalytics>>.
 - Peterson BG, Carl P (2018). *_PortfolioAnalytics: Portfolio Analysis, Including Numerical Methods for Optimization of Portfolios_*. R package version 1.1.0, <<https://CRAN.R-project.org/package=PortfolioAnalytics>>.
 - Laib M, Telesca L, Kanevski M (2019). *_MFDFA: MultiFractal Detrended Fluctuation Analysis_*. R package, version 1.1, <<https://CRAN.R-project.org/package=MFDFA>>.
 - Ryan JA, Ulrich JM (2020). *_xts: eXtensible Time Series_*. R package version 0.12.1, <<https://CRAN.R-project.org/package=xts>>.
 - Wickham et al., (2019). Welcome to the tidyverse. *Journal of Open Source Software*, 4(43), 1686, <https://doi.org/10.21105/joss.01686>
- Python
 - coingecko-api 1.2

Obrigado

Material Suplementar

METODOLOGIA FRACTAL DECOMPOSTA

(1) Construir uma nova série, subtraindo de cada elemento da série a sua média:

$$Y(i) = \sum_{k=1}^i [x_k - \bar{x}], \quad i = 1, 2, \dots, N$$

(2) Subdividir a série em $N_s = \text{int}(N/s)$ janelas não sobrepostas de igual tamanho s . O comprimento N da série pode não ser um múltiplo do tamanho s da janela. Além disso, o procedimento pode não englobar uma pequena parte no final da série $Y(i)$. Assim, a subdivisão da série é realizada também começando pelo final da série, obtendo um total de $2N_s$ janelas. Um polinômio de grau m pode ser aproximado para cada janela, e a variância é calculada por:

$$F(s, v) = \sqrt{\frac{1}{s} \sum_{i=1}^s \{Y[(v-1)s+i] - y_v(i)\}^2}$$

(3) Para cada subintervalo v ($v = 1, 2, \dots, N_s$), a função local de tendência é estimada pelo método dos mínimos quadrados para eliminar a sequência de tendências locais no subintervalo. A variância da sequência do intervalo será:

$$F(s, v) = \sqrt{\frac{1}{s} \sum_{i=1}^s \{Y[N - (v - N_s)s + i] - y_v(i)\}^2}$$

(4) Para cada segmento $v = N(s+1), \dots, 2N_s$ a função de flutuação de ordem q é computada:

$$F_q(s) = \left\{ \frac{1}{2N_s} \sum_{v=1}^{2N_s} [F^s(s, v)]^{\frac{q}{2}} \right\}^{\frac{1}{q}}$$

O expoente Hurst de ordem q pode ser definido pela inclinação $h(q)$ das linhas de regressão para cada ordem q de $F_q(s)$. O parâmetro q amplia flutuações pequenas quando $q < 0$ e as grandes quando $q > 0$.

(5) Determinar o índice de escala da função de flutuação. Para cada valor de q , a série apresenta um comportamento linear na escala log-log. Para cada segmento, obtém-se uma função de flutuação

$$F_q(s) \propto s^{h(q)}$$

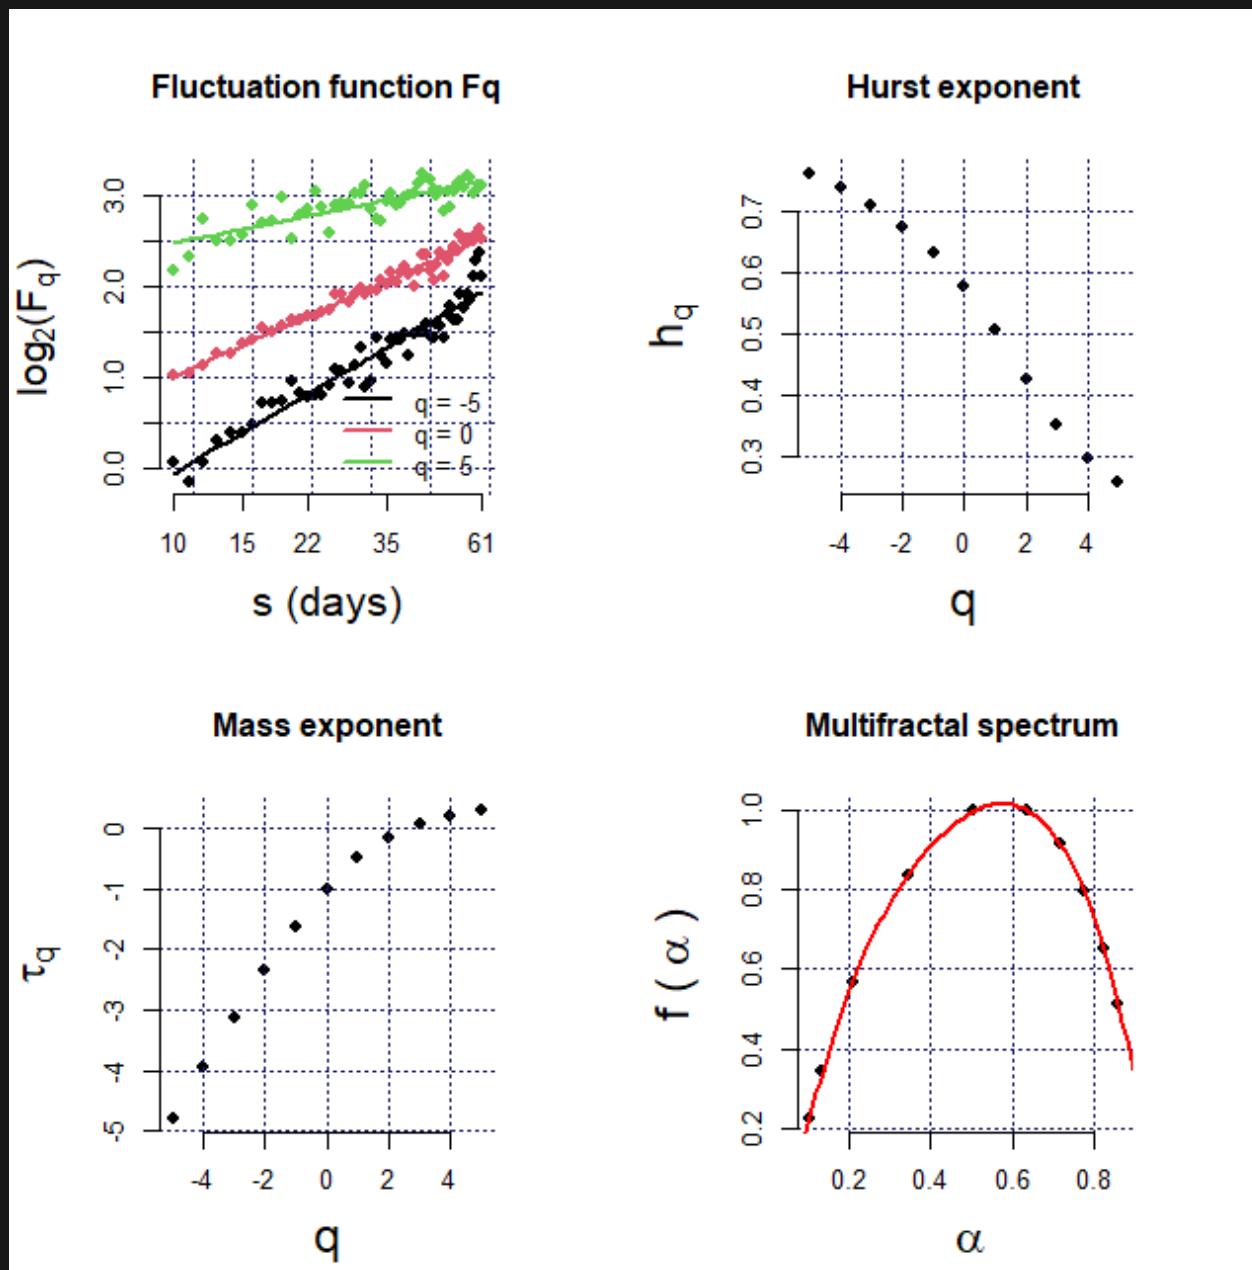
RESULTADOS | MULTIFRACTALIDADE

| Ticker | Moeda | MDM 1 | MDM 2 |
|--------|----------|--------|--------|
| BNB | BNB | 0.1239 | 0.0883 |
| TRX | TRON | 0.1560 | 0.1311 |
| ETH | Ethereum | 0.1230 | 0.1423 |
| BTC | Bitcoin | 0.1893 | 0.1535 |
| LTC | Litecoin | 0.1485 | 0.1786 |
| ADA | Cardano | 0.0778 | 0.1857 |
| XRP | XRP | 0.2530 | 0.2488 |
| DOGE | Dogecoin | 0.2669 | 0.2601 |

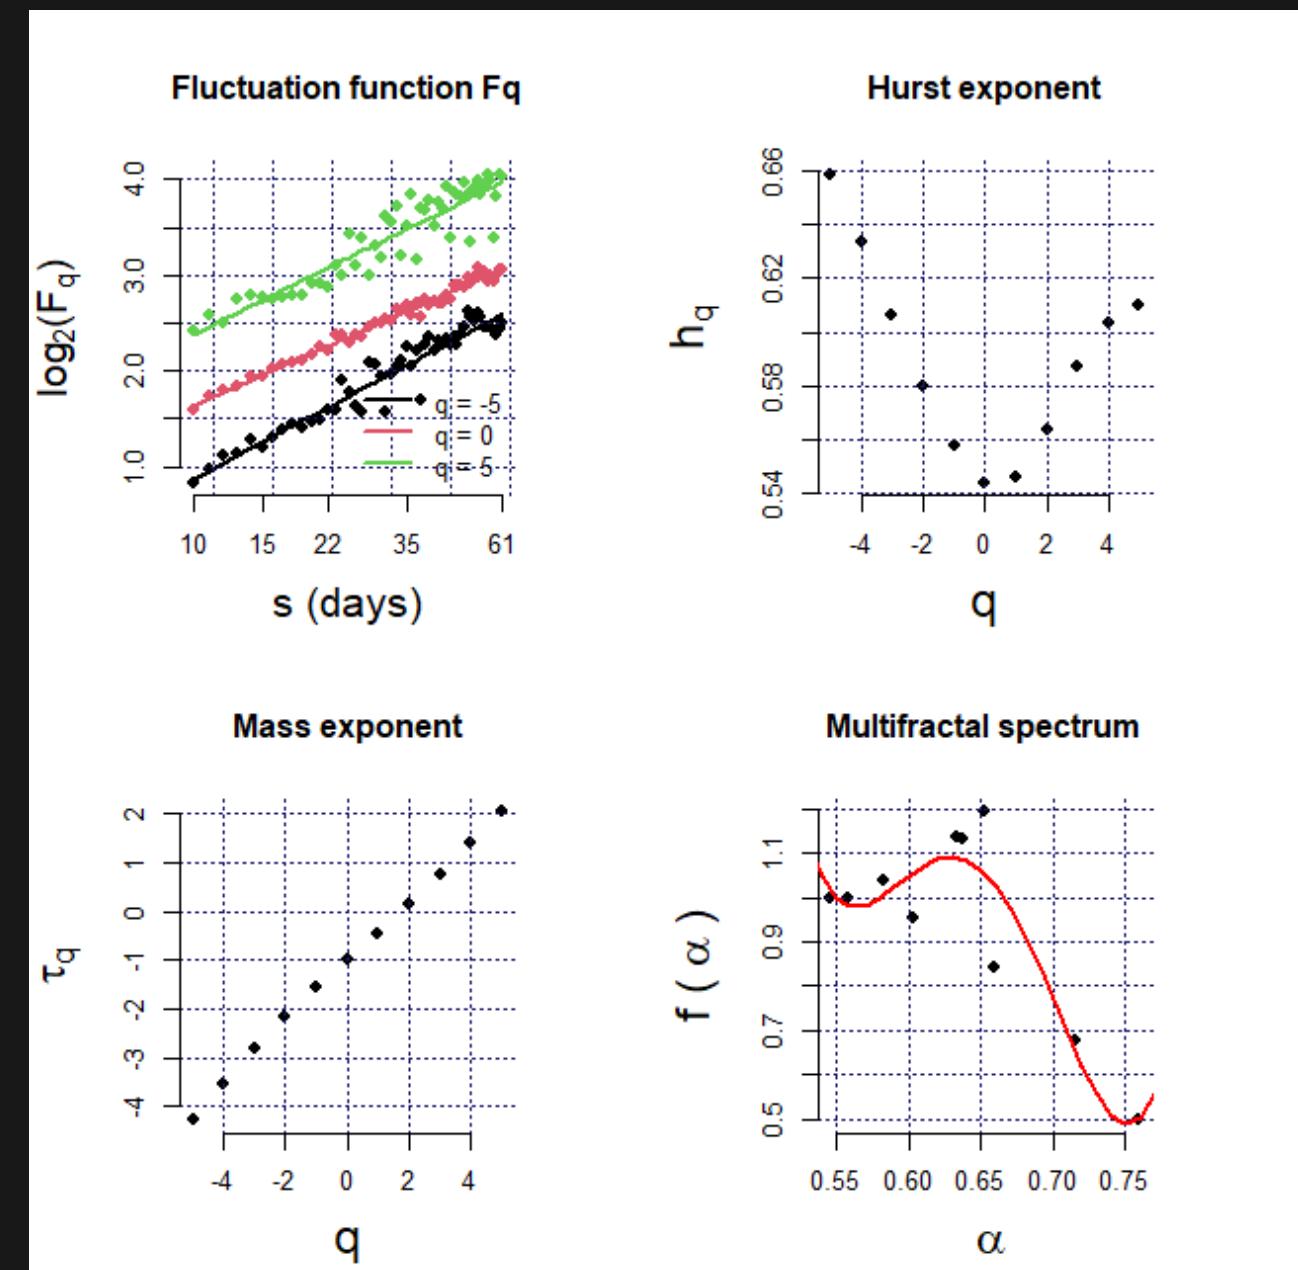
Números em Azul: Gráficos de Multifractalidade a serem apresentados

RESULTADOS | MULTIFRACTALIDADE

Dogecoin- Período 1



BNB - Período 2

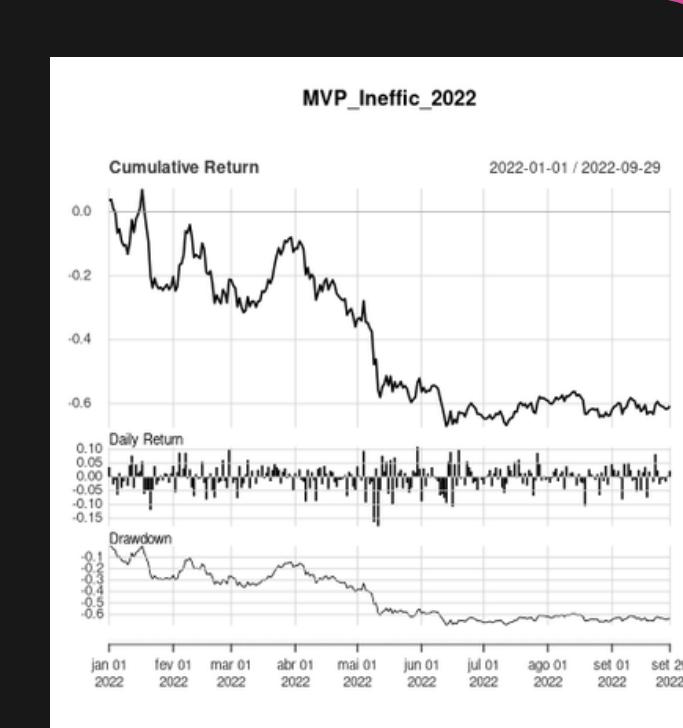
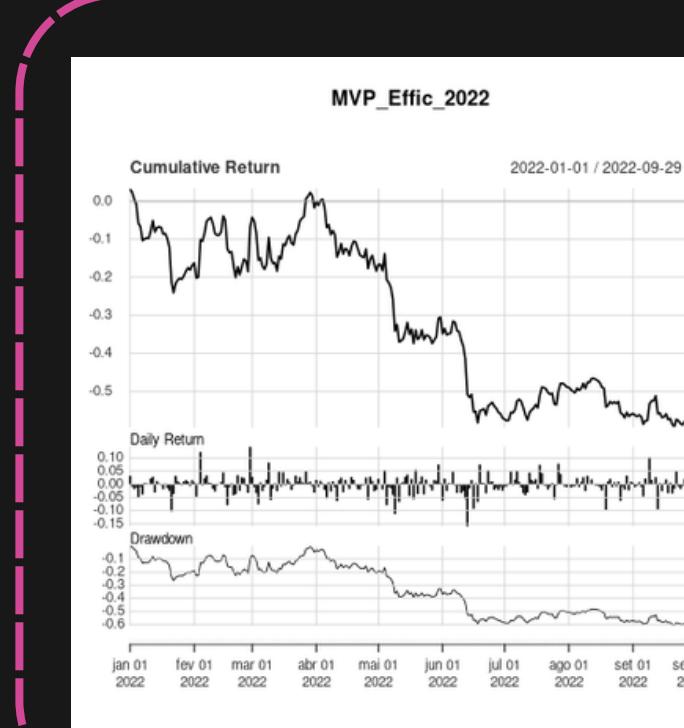
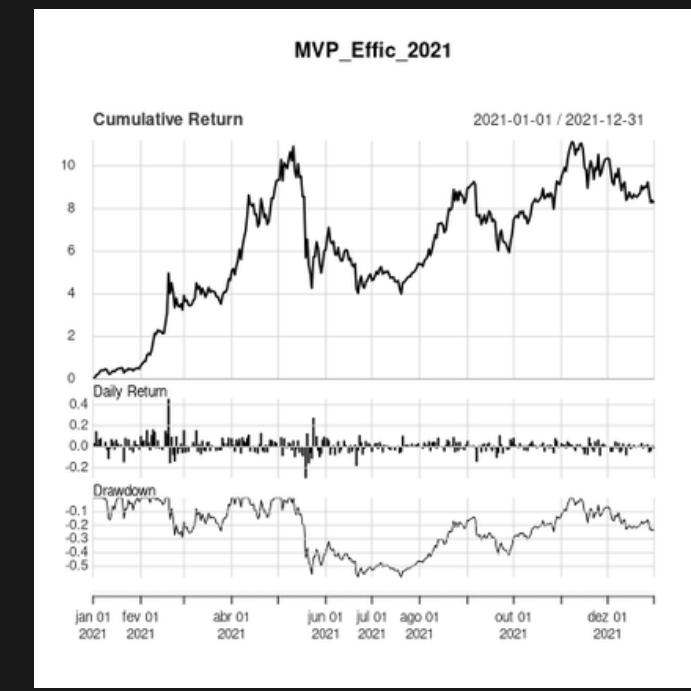
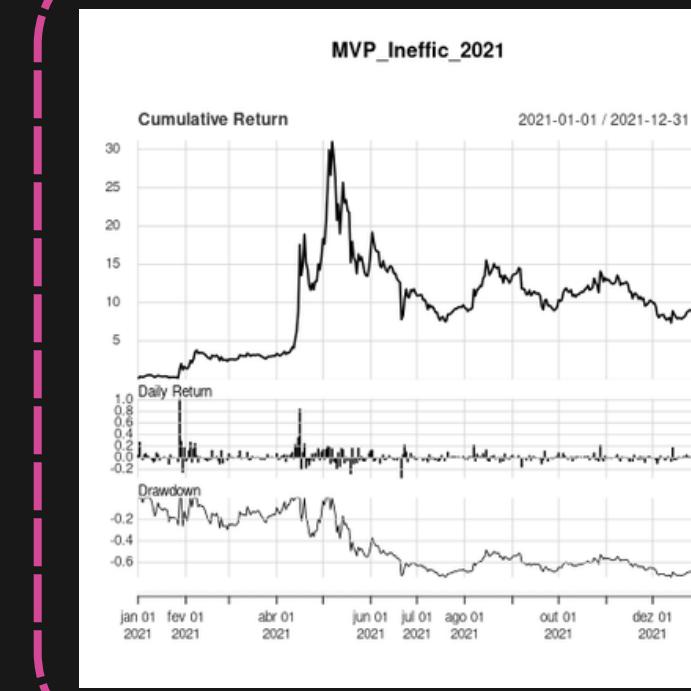
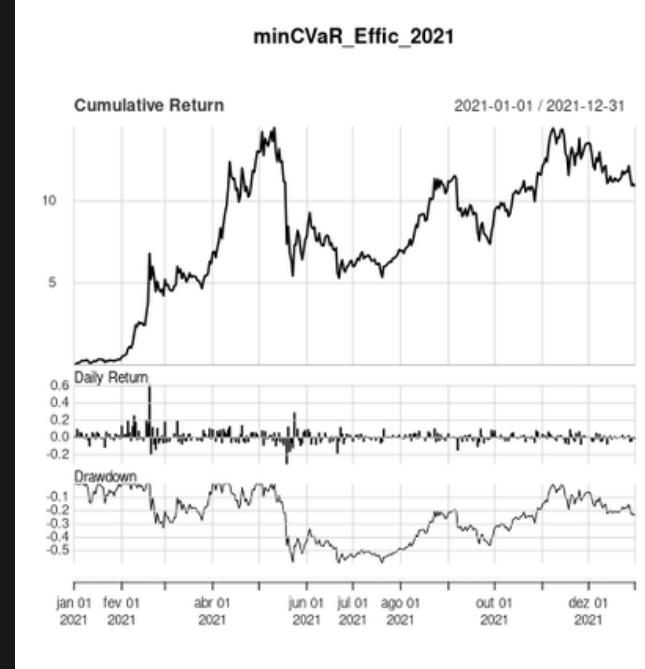
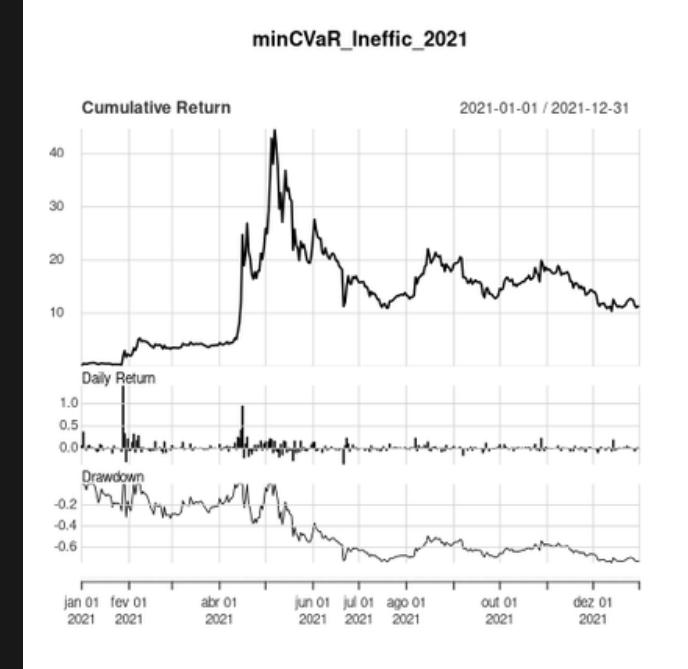


RESULTADOS | OTIMIZAÇÃO DE CARTEIRAS

| Parâmetros de Otimização | Annualized Return | Annualized Std Dev | Annualized Sharpe | Maximum Drawdown |
|--------------------------|-------------------|--------------------|-------------------|------------------|
| MVP_Effic_2021 | 3,6463 | 1,0002 | 0,699 | 0,581 |
| MVP_Ineffic_2021 | 3,5389 | 1,678 | 0,3396 | 0,7388 |
| maxRet_Effic_2021 | 5,0885 | 1,2405 | 1,1628 | 0,613 |
| maxRet_Ineffic_2021 | 0,3809 | 0,6672 | -0,69 | 0,5286 |
| maxSR_Effic_2021 | 3,8579 | 1,0393 | 0,7541 | 0,5899 |
| maxSR_Ineffic_2021 | 0,3809 | 0,6672 | -0,69 | 0,5286 |
| minCVaR_Effic_2021 | 4,5262 | 1,1223 | 1,0072 | 0,5935 |
| minCVaR_Ineffic_2021 | 4,6169 | 1,9662 | 0,4294 | 0,7512 |
| EW_Effic_2021 | 2,7422 | 0,9051 | 0,3897 | 0,5536 |
| EW_Ineffic_2021 | 4,2695 | 1,7017 | 0,4559 | 0,7378 |
| InvInef2021 | 3,1176 | 1,0026 | 0,4634 | 0,6514 |
| | | | | |
| MVP_Effic_2022 | -0,5435 | 0,5516 | -1,7001 | 0,6058 |
| MVP_Ineffic_2022 | -0,5792 | 0,6882 | -1,3736 | 0,6952 |
| maxRet_Effic_2022 | -0,421 | 0,6019 | -1,5339 | 0,6287 |
| maxRet_Ineffic_2022 | -0,6157 | 0,7735 | -1,2269 | 0,7129 |
| maxSR_Effic_2022 | -0,5375 | 0,6526 | -1,4385 | 0,6982 |
| maxSR_Ineffic_2022 | -0,6338 | 0,7538 | -1,2636 | 0,7223 |
| minCVaR_Effic_2022 | -0,55 | 0,5564 | -1,687 | 0,6123 |
| minCVaR_Ineffic_2022 | -0,6245 | 0,7384 | -1,2882 | 0,6123 |
| EW_Effic_2022 | -0,438 | 0,5434 | -1,7017 | 0,5464 |
| EW_Ineffic_2022 | -0,5616 | 0,6709 | -1,4051 | 0,6791 |
| InvInef2022 | -0,4805 | 0,57 | -1,6334 | 0,5956 |

Números em rosa: Gráficos a serem apresentados no slide seguinte

RESULTADOS | OTIMIZAÇÃO DE CARTEIRAS



RESULTADOS | OTIMIZAÇÃO DE CARTEIRAS

